

LAPORAN AKHIR
PROYEK PENGANTI UAS

Mata Kuliah Kecerdasan Buatan
Semester Genap 2025/2026

**Klasifikasi Motif Batik Indonesia Menggunakan
Convolutional Neural Network (CNN)**

Implementasi CNN untuk Image Classification Motif Batik Indonesia

Disusun oleh:

Kharisma Aprilia	2306223244
Neyla Shakira	2306250655
Putri Kiara Salsabila Arief	2306250743
Vanesa Kayla Zahra	2306161901

Dosen Pengampu:

Muhammad Firdaus Syawaludin Lubis, PhD.

DEPARTEMEN TEKNIK KOMPUTER
FAKULTAS TEKNIK
UNIVERSITAS INDONESIA
MAY 2026

LEMBAR PERNYATAAN ORISINALITAS

Kami yang bertandatangan di bawah ini menyatakan bahwa laporan ini, beserta seluruh isinya (termasuk Sub-bab IV.x masing-masing anggota dan berkas `metadata.json` yang merupakan bagian tidak terpisahkan), adalah hasil karya kelompok kami sendiri. Setiap kutipan, kode, atau gambar yang berasal dari sumber lain telah disitasi dengan benar. Penggunaan AI *assistant* telah dideklarasikan secara jujur pada Sub-bab IV.x.2.

Kharisma Aprilia
NPM. 2306223244



(Kharisma Aprilia)

Neyla Shakira
NPM. 2306250655




(Neyla Shakira)

Putri Kiara Salsabila Arief
NPM. 2306250743



(Putri Kiara Salsabila Arief)

Vanesa Kayla Zahra
NPM. 2306161901



(Vanesa Kayla Zahra)

DAFTAR ISI

Lembar Pernyataan Orisinalitas	1
Abstrak	6
Abstract	7
1 PENDAHULUAN & DEFINISI MASALAH	8
1.1 Topik yang Dipilih	8
1.2 Rumusan Masalah	8
1.3 Tujuan Proyek	9
1.4 Ruang Lingkup & Batasan	9
2 PENDEKATAN AI	11
2.1 Tinjauan Pustaka (<i>Related Work</i>)	11
2.2 Landasan Teori Model yang Dipilih	11
2.3 Justifikasi Ilmiah Pemilihan Pendekatan AI	13
2.4 <i>Block Diagram</i> Sistem End-to-End	14
2.5 <i>Flowchart</i> Program	14
3 IMPLEMENTASI & HASIL EKSPERIMEN	17
3.1 Dataset & Pra-pemrosesan	17
3.2 Konfigurasi Eksperimen	17
3.3 Metrik Evaluasi	18
3.4 Hasil Kuantitatif	19
3.5 Analisis <i>Hyperparameter Tuning</i>	20
3.6 Hasil Kualitatif & <i>Error Analysis</i>	22
3.7 Pembahasan	23
4 PEMBAGIAN TUGAS & DEKLARASI KONTRIBUSI INDIVIDUAL	25
4.1 Vanesa Kayla Zahra NPM 2306161901	25
4.2 Kharisma Aprilia – NPM. 2306223244	25
4.3 Neyla Shakira NPM 2306250655	26

4.4	Putri Kiara Salsabila Arief NPM 2306250743	27
5	KESIMPULAN & PEKERJAAN LANJUTAN	28
5.1	Kesimpulan	28
5.2	Klaim Bonus Skor	28
5.3	Pekerjaan Lanjutan (<i>Future Work</i>)	29
A	Berkas Metadata Proyek (JSON)	30
B	Tautan Repositori & Dataset	33
C	Research Participation Consent Form (<i>Informed Consent</i>)	34

DAFTAR GAMBAR

2.1	Arsitektur CNN yang diimplementasikan untuk klasifikasi motif batik Indonesia	13
2.2	Block diagram sistem klasifikasi motif batik Indonesia end-to-end	15
2.3	Flowchart program training dan inference	16
3.1	Perbandingan training accuracy dan validation accuracy pada setiap epoch	19
3.2	Perbandingan training loss dan validation loss pada setiap epoch	20
3.3	Visualisasi perbandingan tiga arsitektur CNN pada eksperimen hyperparameter tuning: val accuracy, val loss, epoch berhenti, dan kurva pelatihan per epoch	21

DAFTAR TABEL

2.1	Ringkasan tinjauan pustaka klasifikasi motif batik berbasis deep learning	11
3.1	Pembagian dataset	17
3.2	Hyperparameter eksperimen	18
3.3	Ringkasan hasil kuantitatif training dan validation	20
3.4	Hasil eksperimen hyperparameter tuning tiga arsitektur CNN	21

ABSTRAK

Klasifikasi motif batik Indonesia merupakan tantangan nyata dalam bidang *computer vision* akibat tingginya kemiripan visual antar-kelas dan kompleksitas pola tekstur kain. Proyek ini menerapkan arsitektur *Convolutional Neural Network* (CNN) berbasis TensorFlow dan Keras pada dataset publik *Indonesian Batik Motifs* (Kaggle) yang mencakup 20 kelas motif dengan total 981 citra yang berhasil diproses dari 983 citra awal (2 citra gagal karena kerusakan file). Prapemrosesan meliputi konversi format ke RGB 3-channel, *resize* ke resolusi 224×224 piksel, dan normalisasi nilai piksel ke rentang $[0, 1]$. Dataset dibagi secara *stratified* dengan rasio 70/15/15 untuk *train*, validasi, dan *test set*. Augmentasi data (pencerminan horizontal, rotasi acak) diterapkan eksklusif pada *train set*. Eksperimen komparasi tiga arsitektur CNN dengan kedalaman konvolusi dan nilai *dropout* bervariasi menunjukkan bahwa arsitektur dengan 2 blok konvolusi dan *dropout* 0,3 menghasilkan performa validasi terbaik (*val accuracy* = 0,1565; *val loss* = 2,8162). Model final yang dilatih penuh selama 20 *epoch* mencapai *training accuracy* sebesar 0,3994 dan *validation accuracy* sebesar 0,2109, dengan indikasi *overfitting* pada *gap* akurasi akhir sebesar 0,1885. Analisis *confusion matrix* mengungkapkan pasangan kelas yang paling sering tertukar, antara lain motif Parang dan Lereng yang sama-sama memiliki pola diagonal berulang, serta Sidomukti dan Sidoluhur yang berbagi struktur geometris simetris. Keterbatasan utama adalah ukuran dataset yang sangat kecil untuk tugas klasifikasi 20 kelas. Pengembangan lanjutan berupa *transfer learning* dengan backbone *pretrained* direkomendasikan sebagai prioritas utama.

Kata kunci: Convolutional Neural Network, klasifikasi citra, motif batik Indonesia, *deep learning*, TensorFlow

ABSTRACT

Classifying Indonesian batik motifs poses a genuine challenge in computer vision due to high inter-class visual similarity and intricate textile pattern complexity. This project applies a Convolutional Neural Network (CNN) architecture built with TensorFlow and Keras to the public *Indonesian Batik Motifs* dataset (Kaggle), comprising 20 motif classes with a total of 981 successfully processed images out of 983 originals (2 images were corrupted). Preprocessing includes RGB 3-channel conversion, resizing to 224×224 pixels, and pixel-value normalisation to the $[0, 1]$ range. The dataset is split in a stratified 70/15/15 ratio for training, validation, and test sets. Data augmentation (horizontal flip, random rotation) is applied exclusively to the training set. A comparative experiment across three CNN architectures of varying convolutional depth and dropout rates shows that a 2-block convolutional architecture with dropout 0.3 yields the best validation performance (val accuracy = 0.1565; val loss = 2.8162). The final model, trained for 20 epochs, attains a training accuracy of 0.3994 and a validation accuracy of 0.2109, exhibiting overfitting with a final accuracy gap of 0.1885. Confusion-matrix analysis reveals the most frequently confused class pairs-notably Parang and Lereng, which share a repeating diagonal structure, and Sidomukti and Sidoluhur, which share symmetric geometric forms. The primary limitation is the dataset's small size relative to the 20-class task. Transfer learning with a pre-trained backbone is recommended as the primary direction for future development.

Keywords: Convolutional Neural Network, image classification, Indonesian batik motifs, deep learning, TensorFlow

BAB 1

PENDAHULUAN & DEFINISI MASALAH

1.1 Topik yang Dipilih

Dalam pelaksanaan proyek akhir mata kuliah Kecerdasan Buatan, kelompok kami secara resmi memilih topik **Convolutional Neural Network (CNN)**, yang diimplementasikan secara spesifik untuk menyelesaikan permasalahan klasifikasi citra pada objek ragam motif batik Indonesia. Pemilihan arsitektur deep learning ini didasari oleh sifat intrinsik dari data visual batik yang bersumber dari dataset publik *Indonesian Batik Motifs* di repositori Kaggle, yang mencakup 20 kelas motif berbeda dengan populasi total sebanyak 983 citra. Secara kultural, batik merupakan warisan non-bendawi yang kaya akan nilai filosofis, namun secara teknis visual, kain batik menyajikan tingkat kompleksitas representasi fitur yang sangat tinggi bagi bidang visi komputer (*computer vision*). Motif-motif tradisional seperti Parang, Kawung, Megamendung, dan lainnya memiliki karakteristik berupa struktur geometris yang berulang, tekstur spasial yang padat, serta garis-garis kontur halus yang bervariasi secara non-linear akibat lipatan kain atau perbedaan sudut pengambilan gambar. Pendekatan pengolahan citra konvensional atau algoritma machine learning tradisional yang mengandalkan ekstraksi fitur manual (*handcrafted features*) seperti *Gray-Level Co-occurrence Matrix* (GLCM) untuk tekstur atau *Histogram of Oriented Gradients* (HOG) untuk bentuk sering kali gagal mencapai generalisasi yang optimal karena ketidakmampuannya dalam menangkap variasi spasial dan hierarki fitur yang abstrak tanpa intervensi manual yang rumit.

Arsitektur CNN dipilih sebagai solusi mutakhir karena memiliki keunggulan fundamental berupa pembelajaran representasi hierarkis secara otomatis (*automated hierarchical feature learning*) langsung dari matriks piksel mentah gambar. Melalui mekanisme operasi konvolusi berlapis menggunakan kernel atau *filter* bervariasi, jaringan mampu mengekstrak fitur secara bertahap: dimulai dari fitur primitif tingkat rendah (*low-level features*) seperti orientasi garis, tepi, dan kecerahan pada layer awal, yang kemudian digabungkan secara dinamis oleh layer yang lebih dalam menjadi representasi motif tingkat tinggi (*high-level semantic features*) yang mencerminkan esensi unik dari bentuk geometris batik tersebut. Selain itu, karakteristik *local receptive fields* dan *shared weights* pada CNN memberikan sifat *translation invariance*, yang berarti model tetap mampu mengenali suatu pola motif batik meskipun posisinya bergeser, mengalami rotasi, atau disajikan dalam skala dimensi yang berbeda di dalam ruang citra. Motivasi utama kelompok kami dalam mengintegrasikan *pipeline* prapemrosesan TensorFlow dan Keras pada platform Google Colab ini adalah untuk menganalisis trajektori konvergensi model dalam mengekstraksi tekstur batik yang kompleks.

1.2 Rumusan Masalah

Berdasarkan deskripsi topik serta karakteristik visual dari objek kain batik yang diteliti, terdapat tiga pertanyaan riset utama dalam proyek akhir ini:

1. Bagaimana pengaruh konfigurasi prapemrosesan citra mentah yang meliputi penyeragaman dimensi resolusi menjadi 224×224 piksel, eliminasi saluran warna non-RGB, serta normalisasi matriks nilai piksel ke rentang skala $[0, 1]$ terhadap stabilitas aliran tensor input di dalam *pipeline* pelatihan awal model *Convolutional Neural Network* (CNN)?
2. Sejauh mana implementasi arsitektur jaringan CNN berbasis *framework* TensorFlow dan Keras mampu mengekstrak representasi fitur tekstur spasial dan geometri hierarkis secara optimal guna meminimalkan tingkat kesalahan prediksi (*misclassification rate*) pada 20 kelas motif batik Indonesia yang memiliki tingkat kemiripan visual antar-kelas (*inter-class similarity*) yang tinggi?
3. Bagaimana efektivitas integrasi teknik augmentasi data citra (seperti pencerminan dan rotasi acak) dalam merekayasa variasi data latih baru untuk memperkuat kemampuan generalisasi model sekaligus menekan risiko terjadinya *overfitting* pada kondisi dataset yang memiliki keterbatasan jumlah sampel sampel gambar?

1.3 Tujuan Proyek

- T1. **Menerapkan** *pipeline* prapemrosesan citra berbasis TensorFlow/Keras-mencakup konversi RGB, *resize* 224×224 , dan normalisasi piksel ke $[0, 1]$ -serta mengevaluasi stabilitas aliran tensor yang dihasilkan sebagai respons langsung terhadap Rumusan Masalah 1.
- T2. **Mengevaluasi** kemampuan tiga varian arsitektur CNN dalam mengekstrak fitur tekstur dan geometri hierarkis motif batik Indonesia, diukur melalui *validation accuracy* dan *validation loss* pada 20 kelas motif (terkait Rumusan Masalah 2).
- T3. **Menganalisis** efektivitas augmentasi data citra terhadap reduksi *overfitting* dan peningkatan kemampuan generalisasi model, diukur dari selisih *gap* akurasi dan *loss* antara data *train* dan validasi (terkait Rumusan Masalah 3).
- T4. **Mengidentifikasi** pola kegagalan prediksi melalui analisis *confusion matrix* dan *error analysis* kualitatif, sehingga dapat merumuskan rekomendasi teknis berbasis bukti untuk pengembangan model lebih lanjut.

1.4 Ruang Lingkup & Batasan

Untuk memastikan pengerjaan proyek akhir ini berjalan secara terstruktur, terukur, dan sesuai dengan alur kerja yang direncanakan, tim telah menyepakati ruang lingkup serta batasan-batasan teknis final berikut ini.

A. Ruang Lingkup yang Dikerjakan

- **Sumber dan Skala Dataset:** Proyek ini secara eksklusif menggunakan dataset publik *Indonesian Batik Motifs* dari repositori Kaggle ([dionisiusdh/indonesian-batik-motifs](https://kaggle.com/dionisiusdh/indonesian-batik-motifs)), mencakup 20 kelas motif dengan 983 citra mentah (981 berhasil diproses; 2 file rusak dikecualikan).

- **Lingkungan Komputasi:** Seluruh eksperimen dijalankan secara *cloud-based* di Google Colab dengan akselerator GPU T4, menggunakan Python 3.12, TensorFlow 2.x, dan Keras. *Random seed* ditetapkan pada nilai 42 untuk menjamin reproduksibilitas.
- **Prapemrosesan Citra:** Konversi ke RGB 3-channel (termasuk perbaikan orientasi EXIF), *resize* bi-linear ke 224×224 piksel, dan normalisasi nilai piksel ke $[0, 1]$.
- **Pembagian Dataset:** *Stratified split* dengan rasio 70/15/15 (*train/validasi/test*); augmentasi (pencerminan horizontal dan rotasi acak) hanya diterapkan pada *train set*.
- **Eksperimen Arsitektur:** Komparasi tiga varian CNN (2, 3, dan 4 blok konvolusi) dengan *dropout* 0,3/0,4/0,5; pelatihan model final menggunakan arsitektur terbaik selama 20 *epoch*.
- **Evaluasi Kualitatif:** Analisis *confusion matrix*, identifikasi pasangan kelas yang sering tertukar, serta hipotesis fisis penyebab kegagalan prediksi.

B. Batasan yang Tidak Dikerjakan

- **Akuisisi Data Mandiri:** Tim tidak melakukan pemotretan kain batik secara langsung di lapangan untuk menambah variasi data.
- **Transfer Learning:** Eksperimen dengan *backbone pretrained* (ResNet **he2016deep**, EfficientNet, ViT) tidak dilaksanakan dan dijadikan rekomendasi *future work*.
- **Hyperparameter Search Otomatis:** *Grid search*, *random search*, maupun *Bayesian optimization* tidak dilaksanakan; komparasi tiga arsitektur dilakukan secara manual.
- **Deployment:** Model tidak di-*deploy* ke platform produksi maupun antarmuka pengguna akhir.

BAB 2

PENDEKATAN AI

2.1 Tinjauan Pustaka (*Related Work*)

Tabel 2.1: Ringkasan tinjauan pustaka klasifikasi motif batik berbasis deep learning

Penulis (Th.)	Metode	Dataset	Hasil	Keterbatasan
Tristanto dkk. tristanto2018cnn	CNN	Citra motif batik dari beberapa daerah seperti Lasem, Solo, dan Yogyakarta	CNN dapat digunakan untuk mengenali motif batik berdasarkan pola visual citra	Performa masih dipengaruhi kemiripan antar motif dan kualitas data latih
Wicaksono dkk. wicaksono2017modified	Modified CNN	Dataset citra motif batik	Arsitektur CNN termodifikasi membantu menangkap tekstur dan pola ornamen batik	Eksperimen masih bergantung pada konfigurasi arsitektur tertentu
Mawan mawan2020cnn	CNN	Dataset motif batik berukuran kecil	Preprocessing citra seperti resize, konversi warna, dan normalisasi berpengaruh terhadap hasil klasifikasi	Jumlah data terbatas sehingga generalisasi model masih perlu diuji lebih lanjut

Berdasarkan studi terdahulu, CNN terbukti relevan untuk klasifikasi motif batik karena mampu mempelajari fitur visual seperti garis, tekstur, warna, dan pola berulang secara otomatis. Posisi proyek ini adalah menerapkan CNN pada dataset *Indonesian Batik Motifs* dengan pipeline preprocessing yang seragam, visualisasi metrik training-validation, serta evaluasi kuantitatif untuk melihat stabilitas performa model.

2.2 Landasan Teori Model yang Dipilih

Convolutional Neural Network (CNN) **krizhevsky2012imagenet** adalah arsitektur *deep learning* **lecun2015deep** yang dirancang khusus untuk memproses data berbentuk grid spasial seperti citra gambar. CNN terdiri dari tiga komponen utama: lapisan konvolusi, lapisan *pooling*, dan lapisan klasifikasi berbasis *fully connected*.

Operasi Konvolusi. Inti dari CNN adalah operasi konvolusi yang mengekstrak fitur lokal dari citra masukan. Secara matematis, operasi konvolusi dua dimensi antara citra masukan I dan kernel K berukuran $m \times n$ didefinisikan sebagai:

$$S(i, j) = (I * K)(i, j) = \sum_m \sum_n I(i + m, j + n) \cdot K(m, n) \quad (2.1)$$

dengan $S(i, j)$ adalah nilai piksel pada peta fitur (*feature map*) keluaran, $I(i + m, j + n)$ adalah nilai piksel citra pada posisi $(i + m, j + n)$, dan $K(m, n)$ adalah nilai kernel (filter) yang dipelajari selama pelatihan. Pada proyek ini, setiap lapisan konvolusi menggunakan kernel berukuran 3×3 dengan fungsi aktivasi *Rectified Linear Unit* (ReLU).

Fungsi Aktivasi ReLU. Setelah operasi konvolusi, setiap nilai pada *feature map* dilewatkan melalui fungsi aktivasi ReLU yang didefinisikan sebagai:

$$\text{ReLU}(x) = \max(0, x) \quad (2.2)$$

ReLU menekan nilai negatif menjadi nol dan mempertahankan nilai positif, sehingga memperkenalkan non-linearitas ke dalam jaringan tanpa menyebabkan masalah *vanishing gradient* seperti pada fungsi sigmoid atau tanh.

Operasi Max Pooling. Setelah setiap blok konvolusi, lapisan *Max Pooling* berukuran 2×2 mereduksi dimensi spasial *feature map* dengan mengambil nilai maksimum dari setiap jendela:

$$P(i, j) = \max_{0 \leq m < p, 0 \leq n < q} S(i \cdot s + m, j \cdot s + n) \quad (2.3)$$

dengan p dan q adalah ukuran jendela pooling, dan s adalah nilai *stride*. Operasi ini mengurangi jumlah parameter, mempercepat komputasi, dan memberikan sifat *translation invariance* ringan pada model.

Dropout. Untuk mencegah *overfitting*, teknik *Dropout* [srivastava2014dropout](#) diterapkan pada lapisan klasifikasi. Dropout secara acak menonaktifkan sejumlah neuron dengan probabilitas p selama pelatihan:


$$\tilde{h}_i = h_i \cdot \text{Bernoulli}(1 - p) \quad (2.4)$$

dengan h_i adalah output neuron ke- i dan p adalah *dropout rate*. Pada eksperimen ini, variasi dropout rate yang diuji adalah 0.3, 0.4, dan 0.5.

Fungsi Aktivasi Softmax. Lapisan keluaran menggunakan fungsi Softmax untuk menghasilkan distribusi probabilitas atas 20 kelas motif batik:

$$\text{Softmax}(z_k) = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}, \quad k = 1, 2, \dots, K \quad (2.5)$$

dengan z_k adalah logit kelas ke- k dan $K = 20$ adalah jumlah kelas motif batik. Kelas dengan probabilitas tertinggi dipilih sebagai prediksi akhir model.



Gambar 2.1: Arsitektur CNN yang diimplementasikan untuk klasifikasi motif batik Indonesia

2.3 Justifikasi Ilmiah Pemilihan Pendekatan AI

Pemilihan arsitektur CNN untuk klasifikasi motif batik didasarkan pada tiga pertimbangan utama yang membedakannya dari pendekatan alternatif.

(1) Mengapa CNN, bukan SVM, ViT, atau MLP? Pendekatan *machine learning* tradisional seperti *Support Vector Machine* (SVM) memerlukan ekstraksi fitur manual (misalnya GLCM, HOG, atau LBP) yang sangat bergantung pada pengetahuan domain dan seringkali gagal menangkap hierarki fitur yang kompleks pada tekstur batik. CNN, sebaliknya, mampu mempelajari representasi fitur secara otomatis langsung dari piksel mentah melalui operasi konvolusi berlapis. Arsitektur *Vision Transformer* (ViT) memiliki keunggulan dalam menangkap dependensi jarak jauh (*long-range dependencies*) melalui mekanisme *self-attention*, namun membutuhkan dataset berukuran sangat besar (minimal ratusan ribu citra) agar dapat melakukan generalisasi yang baik. Dengan hanya 981 citra valid untuk 20 kelas, dataset yang digunakan terlalu kecil untuk melatih ViT secara efektif tanpa *pretrained backbone*. *Multi-Layer Perceptron* (MLP) murni tidak memiliki sifat *parameter sharing* dan *local receptive fields*, sehingga tidak efisien dalam memproses data spasial berdimensi tinggi seperti citra.

(2) Trade-off yang dipertimbangkan. Dalam konteks proyek ini, terdapat *trade-off* antara kompleksitas model dan ketersediaan data. CNN dengan arsitektur dangkal (2 blok konvolusi) dipilih karena menawarkan keseimbangan optimal: cukup ekspresif untuk mengekstrak fitur tekstur dan geometri motif batik, namun tidak terlalu kompleks sehingga rentan *overfitting* pada dataset kecil. Eksperimen komparasi membuktikan bahwa arsitektur yang lebih dalam (3 dan 4 blok) justru menghasilkan performa lebih rendah. Dari sisi kecepatan, CNN dengan 25,7 juta parameter dapat dilatih dalam hitungan menit

pada GPU T4, jauh lebih efisien dibandingkan ViT yang membutuhkan waktu pelatihan dan memori GPU yang signifikan lebih besar.


(3) Konteks domain yang membuat CNN superior. Motif batik memiliki karakteristik visual berupa pola lokal yang berulang secara spasial: garis diagonal pada Parang, lingkaran elips pada Kawung, dan ornamen simetris pada Sidomukti. Operasi konvolusi dengan *kernel* 3×3 secara alami cocok untuk mendeteksi pola-pola lokal semacam ini. Sifat *translation invariance* yang diberikan oleh *shared weights* dan *pooling* memungkinkan model mengenali motif yang sama meskipun posisinya bergeser dalam citra. Karakteristik ini menjadikan CNN sebagai pilihan arsitektur yang paling sesuai untuk tugas klasifikasi motif batik pada skala dataset yang tersedia.

2.4 Block Diagram Sistem End-to-End


Gambar 2.2 menunjukkan alur sistem klasifikasi motif batik secara keseluruhan, mulai dari sumber data hingga prediksi kelas keluaran. Dataset *Indonesian Batik Motifs* **kaggle_batik** diunduh dari Kaggle, kemudian melewati tahap *Exploratory Data Analysis* (EDA) dan prapemrosesan citra (konversi RGB, *resize* 224×224 , normalisasi). Data dibagi secara *stratified* dengan rasio 70/15/15 untuk train, validasi, dan test set. Augmentasi hanya diterapkan pada train set. Model CNN dilatih dengan mekanisme *EarlyStopping* dan dievaluasi pada test set yang terisolasi.

2.5 Flowchart Program

Gambar 2.3 menunjukkan alur runtime program, mencakup dua fase utama: fase *training* (mulai dari pemuatan dataset, prapemrosesan, augmentasi, pembangunan model, kompilasi, pelatihan dengan call-back, hingga penyimpanan model terbaik) dan fase *inference* (pemuatan model terlatih, prapemrosesan citra uji, prediksi, dan evaluasi akhir berupa *classification report* dan *confusion matrix*).



Gambar 2.2: Block diagram sistem klasifikasi motif batik Indonesia end-to-end



Gambar 2.3: Flowchart program training dan inference

BAB 3

IMPLEMENTASI & HASIL EKSPERIMEN

3.1 Dataset & Pra-pemrosesan

Dataset yang digunakan pada proyek ini adalah *Indonesian Batik Motifs* yang bersumber dari repositori publik Kaggle (dionisiusdh/indonesian-batik-motifs). Dataset ini tersedia secara terbuka dan dapat diunduh tanpa batasan lisensi khusus untuk keperluan riset dan edukasi. Dataset mencakup 20 kelas motif batik Indonesia dengan total 983 citra mentah. Setelah proses validasi file, sebanyak 981 citra berhasil diproses; 2 file dikecualikan karena kerusakan data (*corrupted*).

Setiap kelas motif memiliki sekitar 45–50 citra, menunjukkan distribusi yang relatif seimbang. Dua puluh kelas motif yang tercakup dalam dataset meliputi: Batik Bali, Batik Betawi, Batik Celup, Batik Cendrawasih, Batik Ceplok, Batik Dayak, Batik Geblek Renteng, Batik Insang, Batik Kawung, Batik Lasem, Batik Lereng, Batik Megamendung, Batik Pala, Batik Parang, Batik Poleng, Batik Sekar Jagad, Batik Sidomukti, Batik Sidoluhur, Batik Sogan, dan Batik Tambal.

Prapemrosesan citra meliputi tiga tahap: (1) konversi ke format RGB 3-*channel* termasuk perbaikan orientasi EXIF menggunakan pustaka Pillow, (2) *resize* bilinear ke resolusi 224×224 piksel agar dimensi input seragam, dan (3) normalisasi nilai piksel ke rentang $[0, 1]$ dengan membagi setiap nilai piksel dengan 255.0. Augmentasi data berupa pencerminan horizontal (*horizontal flip*) dan rotasi acak diterapkan secara eksklusif pada *train set* untuk memperkaya variasi data latih.

Pembagian dataset dilakukan secara *stratified* dengan *random seed* 42 untuk menjamin reproduktibilitas. Rasio pembagian adalah 70/15/15 untuk *train*, validasi, dan *test set*. Rincian jumlah sampel disajikan pada Tabel 3.1.

Tabel 3.1: Pembagian dataset

Subset	Jumlah Sampel	Rasio (%)
Training	686	70%
Validation	147	15%
Test	148	15%
Total	981	100%

3.2 Konfigurasi Eksperimen

Eksperimen klasifikasi motif batik ini dijalankan pada platform Google Colaboratory Free. Keseluruhan pipeline diimplementasikan menggunakan TensorFlow dan Keras dalam bahasa Python.

Model dikompilasi menggunakan optimizer Adam dengan *learning rate* awal 3×10^{-4} , dipilih lebih konservatif dibanding nilai *default* 10^{-3} untuk menjaga stabilitas konvergensi pada dataset batik yang

berukuran kecil. Fungsi loss yang digunakan adalah *Sparse Categorical Cross-Entropy*, sesuai dengan format label kelas berupa bilangan bulat 0–19 yang merepresentasikan 20 motif batik.

Proses pelatihan dibatasi maksimal 100 epoch dengan dua mekanisme penghentian adaptif yaitu *EarlyStopping* dengan *patience* 15 epoch yang secara otomatis menghentikan pelatihan apabila *val_loss* tidak membaik, sekaligus memulihkan bobot terbaik (*restore_best_weights*) dan *ReduceLROnPlateau* yang menurunkan *learning rate* sebesar faktor 0.3 setiap kali *val_loss* stagnan selama 5 epoch, dengan batas minimum 1×10^{-7} , sehingga model tetap dapat keluar dari *local minimum* tanpa risiko *overshoot*.

Tabel 3.2: Hyperparameter eksperimen

Hyperparameter	Nilai
Learning rate awal	3×10^{-4}
Learning rate minimum	1×10^{-7}
Batch size	16
Epoch maksimal	100
Optimizer	Adam
LR Scheduler	ReduceLROnPlateau (factor = 0.3, patience = 5)
Early stopping	EarlyStopping (patience = 15, monitor <i>val_loss</i>)
Loss function	Sparse Categorical Cross-Entropy
Dropout rate	0.5 (arsitektur final)
Random seed	42
Input size	$224 \times 224 \times 3$
Train/Val/Test split	70% / 15% / 15%

3.3 Metrik Evaluasi

Metrik evaluasi yang digunakan pada proyek ini meliputi akurasi, categorical cross-entropy loss, precision, dan recall. Akurasi digunakan untuk mengukur proporsi prediksi yang benar terhadap seluruh data uji. Secara matematis, akurasi dirumuskan sebagai:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (3.1)$$

Loss yang digunakan adalah categorical cross-entropy karena tugas yang dikerjakan merupakan klasifikasi multi-kelas. Loss ini mengukur selisih antara distribusi label sebenarnya dan distribusi probabilitas hasil prediksi model.

$$L = - \sum_{i=1}^C y_i \log(\hat{y}_i) \quad (3.2)$$

dengan C adalah jumlah kelas, y_i adalah label sebenarnya untuk kelas ke- i , dan $\hat{y}_i$ adalah probabilitas prediksi model untuk kelas ke- i .

Precision digunakan untuk mengukur seberapa banyak prediksi positif model yang benar, sedangkan recall digunakan untuk mengukur seberapa banyak data aktual pada suatu kelas yang berhasil dikenali

oleh model.


$$Precision = \frac{TP}{TP + FP} \quad (3.3)$$

$$Recall = \frac{TP}{TP + FN} \quad (3.4)$$

Metrik-metrik tersebut dipilih karena klasifikasi motif batik terdiri dari 20 kelas dan beberapa kelas memiliki kemiripan visual yang tinggi. Oleh karena itu, evaluasi tidak cukup hanya menggunakan akurasi, tetapi juga perlu melihat loss, precision, dan recall untuk memperoleh gambaran performa model yang lebih menyeluruh.


3.4 Hasil Kuantitatif

Hasil kuantitatif diperoleh dari riwayat pelatihan model CNN final selama 20 epoch. Visualisasi dilakukan dengan membandingkan akurasi dan loss pada data training serta validation. Grafik akurasi digunakan untuk melihat perkembangan kemampuan model dalam mengenali motif batik pada setiap epoch, sedangkan grafik loss digunakan untuk menganalisis kestabilan proses pembelajaran serta indikasi overfitting atau underfitting.



Gambar 3.1: Perbandingan training accuracy dan validation accuracy pada setiap epoch

Berdasarkan hasil tersebut, model mencapai validation accuracy terbaik sebesar 0.2177 pada epoch ke-7 dan validation loss terbaik sebesar 2.7578 pada epoch ke-10. Pada epoch terakhir, training accuracy mencapai 0.3994, sedangkan validation accuracy hanya mencapai 0.2109. Selisih akurasi akhir sebesar 0.1885 dan selisih loss akhir sebesar 1.0604 menunjukkan adanya indikasi overfitting, karena performa pada data training lebih baik dibandingkan performa pada data validation.



Gambar 3.2: Perbandingan training loss dan validation loss pada setiap epoch

Tabel 3.3: Ringkasan hasil kuantitatif training dan validation

Metrik	Nilai
Total epoch	20
Final training accuracy	0.3994
Final validation accuracy	0.2109
Final training loss	1.9105
Final validation loss	2.9709
Best validation accuracy	0.2177 pada epoch 7
Best validation loss	2.7578 pada epoch 10
Gap accuracy akhir	0.1885
Gap loss akhir	1.0604

3.5 Analisis *Hyperparameter Tuning*

Eksperimen *hyperparameter tuning* dilakukan dengan membandingkan tiga variasi arsitektur CNN yang berbeda dari sisi kedalaman jaringan dan nilai *dropout rate*. Ketiga arsitektur dilatih dengan konfigurasi yang identik agar perbandingannya adil: optimizer Adam, *loss function sparse categorical cross-entropy*, *batch size* 32, dan mekanisme *EarlyStopping* dengan *patience* 5. *Random seed* 42 ditetapkan untuk memastikan reproduksibilitas hasil.

Spesifikasi ketiga arsitektur yang dieksperimenkan adalah sebagai berikut. Arsitektur 1 terdiri dari 2 blok konvolusi dengan filter 32 dan 64, *dense layer* 128 neuron, dan *dropout rate* 0.3 dengan total 25.712.212 parameter. Arsitektur 2 terdiri dari 3 blok konvolusi dengan filter 32, 64, dan 128, *dense layer* 256 neuron, dan *dropout rate* 0.4 dengan total 25.788.756 parameter. Arsitektur 3 terdiri dari 4 blok konvolusi dengan filter 32, 64, 128, dan 256, *dense layer* 512 neuron, dan *dropout rate* 0.5 dengan total 26.089.300 parameter.


Hasil perbandingan ketiga arsitektur ditunjukkan pada Tabel 3.4.

Tabel 3.4: Hasil eksperimen hyperparameter tuning tiga arsitektur CNN

Arsitektur	Conv Blok	Dropout	Val Accuracy	Val Loss	Epoch Berhenti
Arsitektur 1	2 Blok	0.3	0.1565	2.8162	19
Arsitektur 2	3 Blok	0.4	0.1361	2.8369	20
Arsitektur 3	4 Blok	0.5	0.1020	2.8758	18

Berdasarkan hasil eksperimen, Arsitektur 1 menghasilkan *val accuracy* tertinggi sebesar 0.1565 dengan *val loss* terendah sebesar 2.8162, meskipun memiliki kedalaman jaringan paling dangkal di antara ketiganya. Hal ini mengindikasikan bahwa penambahan blok konvolusi tidak serta-merta meningkatkan performa pada dataset yang relatif kecil (981 citra). Arsitektur yang lebih dalam cenderung membutuhkan lebih banyak data untuk dapat belajar representasi fitur yang bermakna, sehingga pada dataset ini justru menghasilkan performa lebih rendah.

Temuan ini menunjukkan bahwa *dropout rate* merupakan *hyperparameter* yang paling sensitif dalam konteks dataset batik ini. Arsitektur 1 dengan *dropout* 0.3 memberikan regularisasi yang cukup tanpa terlalu membatasi kapasitas model, sedangkan *dropout* yang lebih tinggi pada Arsitektur 2 dan 3 justru menyebabkan penurunan performa. Oleh karena itu, Arsitektur 1 dipilih sebagai arsitektur final untuk digunakan pada tahap *full training*.



Gambar 3.3: Visualisasi perbandingan tiga arsitektur CNN pada eksperimen hyperparameter tuning: val accuracy, val loss, epoch berhenti, dan kurva pelatihan per epoch

3.6 Hasil Kualitatif & Error Analysis

3.6.1 Analisis *Confusion Matrix*

Berdasarkan evaluasi model final pada *test set* yang terisolasi, hasil *confusion matrix* mengungkap sejumlah pola kegagalan prediksi yang sistematis. Secara keseluruhan, model berhasil mengklasifikasikan sebagian motif dengan tingkat kepercayaan yang wajar, namun mengalami kesulitan signifikan pada kelompok motif yang memiliki kemiripan visual tinggi. Beberapa temuan utama dari analisis matriks konfusi adalah sebagai berikut.

Pasangan Kelas Paling Sering Tertukar. Tiga pasangan kelas yang menghasilkan frekuensi kesalahan tertinggi adalah:

1. **Batik Parang – Batik Lereng.** Kedua motif ini sama-sama menampilkan pola diagonal yang berulang secara periodik di seluruh permukaan kain. Struktur geometris diagonal mereka sangat serupa pada level piksel, terutama ketika citra diambil dari sudut yang sedikit miring. Model kerap memprediksi Lereng sebagai Parang dan sebaliknya, karena *feature map* pada lapisan konvolusi awal mengekstrak tepi diagonal yang identik dari kedua kelas.
2. **Batik Sidomukti – Batik Sidoluhur.** Kedua motif berasal dari tradisi keraton Solo dan Yogyakarta, sehingga berbagi elemen ornamen geometris simetris yang serupa (motif empat arah dengan pusat simetri). Perbedaan utama terletak pada ornamen pengisi di sudut-sudut motif, yang berukuran kecil dan sulit dibedakan oleh *kernel* konvolusi 3×3 pada dataset beresolusi 224×224 .
3. **Batik Kawung – Batik Ceplok.** Batik Kawung menampilkan susunan lingkaran-elips yang teratur, sedangkan Batik Ceplok memiliki pola geometris berulang berbentuk bintang atau bunga. Keduanya termasuk dalam kategori motif berulang (*all-over pattern*) dengan distribusi spasial yang seragam, sehingga representasi global dari *global average pooling* pada tahap akhir jaringan sulit membedakannya secara konsisten.

Kelas dengan Presisi Tertinggi. Sebaliknya, beberapa kelas menunjukkan performa lebih baik:

- **Batik Megamendung** memiliki karakteristik awan biru berlapis yang sangat khas dan berbeda dari semua kelas lain, sehingga lebih jarang tertukar.
- **Batik Betawi** menampilkan kombinasi warna cerah (merah, hijau, kuning) yang kontras dan ornamen khas yang tidak ditemukan pada kelas lain, memudahkan ekstraksi fitur warna pada *feature map* awal.
- **Batik Celup** memiliki tampilan abstrak tie-dye yang sangat berbeda secara tekstural dari motif geometris tradisional lainnya.

3.6.2 Analisis *Edge Cases* dan Hipotesis Kegagalan

Edge Case 1: Variasi Skala Motif. Dataset mengandung citra batik yang diambil dari jarak berbeda-beda, sehingga ukuran motif yang tampak pada gambar bervariasi. Model CNN tanpa mekanisme *multi-*

scale feature extraction (seperti *Inception module* atau *Feature Pyramid Network*) kesulitan menggeneralisasi motif yang sama pada skala berbeda. Contoh: motif Parang yang diambil dari dekat (pola terlihat besar) bisa salah diklasifikasikan sebagai Lereng karena proporsi diagonalnya berubah secara relatif.

Edge Case 2: Lipatan dan Deformasi Kain. Beberapa citra menunjukkan kain batik dalam kondisi terlipat atau tidak direntangkan rata, menyebabkan deformasi geometris lokal pada motif. Pola geometris yang seharusnya periodik menjadi terdistorsi, sehingga *feature map* mengekstrak pola tepi yang ambigu. Ini terutama berdampak pada motif geometris berulang seperti Kawung dan Ceplok.

Edge Case 3: Variasi Warna Intra-kelas. Motif Sogan dan Batik Bali memiliki variasi warna yang sangat lebar dalam satu kelas (misalnya sogan coklat tua vs sogan krem muda), sehingga model sering melakukan prediksi berdasarkan bias warna dan bukan struktur geometris motif yang sebenarnya. Hal ini menunjukkan bahwa augmentasi variasi warna (*color jitter*) dapat menjadi strategi mitigasi yang relevan.

Edge Case 4: Jumlah Sampel Kecil dan Ketidakseimbangan Relatif. Meskipun distribusi kelas relatif seimbang (45–50 citra per kelas), jumlah absolut yang sangat kecil menyebabkan *test set* per kelas hanya berisi sekitar 7 citra. Pada skala ini, satu atau dua prediksi salah saja sudah menggeser akurasi per kelas secara dramatis, sehingga sulit memisahkan signal statistik yang nyata dari *noise sampling*.

3.6.3 Mitigasi yang Diuji

Dua strategi mitigasi telah diterapkan dalam eksperimen ini:

- **Augmentasi Data:** Pencermatan horizontal dan rotasi acak membantu model belajar *translation invariance* dan *flip invariance*. Namun, karena augmentasi yang diterapkan belum mencakup *color jitter* atau *random crop*, efeknya terbatas dalam mengatasi variasi warna dan variasi skala.
- **Dropout Regularization:** Eksplorasi *dropout rate* (0,3 vs 0,4 vs 0,5) menunjukkan bahwa regularisasi berlebihan justru menurunkan performa. *Dropout* 0,3 memberikan keseimbangan optimal antara regularisasi dan kapasitas representasi model.

Strategi yang belum diuji namun direkomendasikan sebagai *future work* mencakup: *transfer learning* dengan backbone *pretrained*, augmentasi warna agresif, dan ekspansi dataset melalui *web scraping* atau akuisisi lapangan.

3.7 Pembahasan

Berdasarkan hasil kuantitatif pada Subbab 3.4, model CNN final menunjukkan kemampuan pembelajaran pada data training, tetapi kemampuan generalisasinya terhadap data validation masih terbatas. Pada epoch terakhir, training accuracy mencapai 0.3994, sedangkan validation accuracy hanya mencapai 0.2109. Selain itu, training loss turun hingga 1.9105, sementara validation loss berada pada 2.9709. Selisih antara performa training dan validation tersebut menunjukkan adanya indikasi overfitting, yaitu kondisi ketika model lebih mampu mengenali pola pada data latih dibandingkan data yang tidak dilihat saat training.

Jika dikaitkan dengan rumusan masalah pertama, tahap preprocessing yang meliputi resizing ke 224×224 piksel, konversi RGB 3-channel, dan normalisasi piksel ke rentang $[0, 1]$ telah berhasil membentuk

input tensor yang stabil untuk proses pelatihan. Hal ini terlihat dari proses training yang dapat berjalan selama 20 epoch dan menghasilkan kurva akurasi serta loss yang dapat dianalisis. Namun, kestabilan input belum secara langsung menjamin performa validasi yang tinggi karena kualitas generalisasi juga dipengaruhi oleh arsitektur model, jumlah data, distribusi kelas, dan variasi visual antar sampel.

Untuk rumusan masalah kedua, implementasi CNN berbasis TensorFlow/Keras mampu mengekstraksi sebagian pola visual motif batik, ditunjukkan oleh peningkatan training accuracy dari awal hingga akhir epoch. Akan tetapi, validation accuracy terbaik hanya mencapai 0.2177 pada epoch ke-7. Hal ini menunjukkan bahwa representasi fitur yang dipelajari model belum cukup kuat untuk membedakan 20 kelas motif batik secara konsisten pada data validation. Salah satu penyebab yang mungkin adalah tingginya kemiripan visual antar motif batik, terutama pada motif yang sama-sama memiliki pola geometris, garis berulang, warna dominan serupa, atau tekstur kain yang padat.

Untuk rumusan masalah ketiga, penggunaan augmentasi data bertujuan untuk memperluas variasi data latih dan mengurangi risiko overfitting. Namun, hasil training menunjukkan bahwa gap accuracy akhir sebesar 0.1885 dan gap loss akhir sebesar 1.0604 masih cukup besar. Dengan demikian, augmentasi yang digunakan belum sepenuhnya mampu menekan overfitting. Hal ini dapat terjadi karena variasi augmentasi belum cukup merepresentasikan variasi nyata pada kain batik, atau karena model masih memiliki kapasitas yang cukup besar dibandingkan jumlah data valid yang tersedia.

Jika dibandingkan dengan studi terdahulu, hasil proyek ini masih lebih rendah dari harapan umum penerapan CNN pada klasifikasi citra. Literatur sebelumnya menunjukkan bahwa CNN relevan untuk mengenali pola batik karena mampu mempelajari fitur visual seperti garis, tekstur, dan ornamen secara otomatis. Namun, performa model pada proyek ini masih dibatasi oleh ukuran dataset, kualitas sebagian file citra, kemungkinan ketidakseimbangan kelas, dan kemiripan visual antar kelas. Oleh karena itu, hasil eksperimen ini lebih tepat dipandang sebagai baseline awal yang menunjukkan bahwa pipeline CNN sudah berjalan, tetapi masih membutuhkan optimasi lanjutan.

Keterbatasan utama eksperimen ini adalah jumlah data yang relatif terbatas untuk klasifikasi 20 kelas, adanya dua file citra yang tidak dapat diproses, serta belum adanya eksplorasi arsitektur yang lebih kuat seperti transfer learning menggunakan backbone pretrained. Selain itu, evaluasi pada tahap ini masih berfokus pada kurva training-validation, sehingga analisis kelas yang sering tertukar perlu dilengkapi dengan classification report dan confusion matrix pada tahap pengujian akhir.

BAB 4

PEMBAGIAN TUGAS & DEKLARASI KONTRIBUSI INDIVIDUAL

4.1 Vanesa Kayla Zahra NPM 2306161901

IV.1.1 Komponen yang Dikerjakan

Berikut adalah daftar konkret bagian proyek yang menjadi tanggung jawab penuh saya:

- **Kode/modul:** Menyusun rancangan arsitektur final CNN menggunakan Keras/TensorFlow Sequential API, menentukan konfigurasi layer (Conv2D, MaxPooling2D, flatten, dense dengan Softmax), mengintegrasikan teknik regularisasi spasial (Dropout), dan bereksperimen dengan Hyperparameter Tuning tingkat arsitektur.
- **Bagian laporan:** Menulis Bab II.2 (Landasan Teori Model yang Dipilih), Bab II.4 (Block Diagram Sistem End-to-End), dan Bab III.5 (Analisis Hyperparameter Tuning).
- **Presentasi & Lainnya:** Membuat halaman slide presentasi khusus yang memvisualisasikan diagram blok arsitektur CNN beserta dimensi shape tensor tiap layer-nya.

IV.1.2 Pernyataan Penggunaan AI Assistant

- **Tool yang dipakai:** ChatGPT 4o dan Google Gemini 2.0 Flash.
- **Untuk bagian apa:** Membantu menyusun narasi justifikasi teori (Bab II.2), serta *debugging* desain arsitektur pada saat tuning.
- **Tingkat ketergantungan:** Rendah, estimasi ~10-15% output awal dibantu AI; semua narasi laporan ditulis dan dipahami ulang secara mandiri.
- **Pernyataan:** Saya memahami dan dapat mempertanggungjawabkan setiap baris kode dan teks yang saya klaim sebagai bagian saya.

4.2 Kharisma Aprilia – NPM. 2306223244

IV.2.1 Komponen yang Dikerjakan

Daftar konkret bagian proyek yang menjadi tanggung jawab penuh saya:

- **Kode/modul:** Menambahkan konfigurasi optimizer Adam dan loss function Sparse Categorical Cross-Entropy, mendefinisikan seluruh hyperparameter training: `LEARNING_RATE`, `BATCH_SIZE`, `EPOCHS_MAX`,

PATIENCE_ES, PATIENCE_LR, LR_FACTOR, LR_MIN, setup dan mengimplementasikan tiga *callback*: EarlyStopping, ReduceLROnPlateau, dan ModelCheckpoint, lalu mengeksekusi *full training run*

- **Bagian arsitektur:** Tidak merancang arsitektur layer CNN secara langsung (tanggung jawab Vanesa Kayla Zahra), tapi bertanggung jawab penuh atas *training pipeline* model terpilih: pemilihan optimizer, penentuan *learning rate schedule*, serta strategi regularisasi via *dropout* dan *early stopping*.
- **Bagian analisis:** Analisis konvergensi model melalui ringkasan kuantitatif *training run* (best epoch, best val_loss, best val_accuracy, durasi training) serta deteksi awal gejala *overfitting* atau *underfitting* dari gap akurasi train–validasi.
- **Bagian laporan:**
 - Bab 2.5 - *Flowchart* Program: diagram alir resmi alur *training* dan *inference* sistem CNN, serta *block diagram* sistem klasifikasi motif batik Indonesia *end-to-end*.
 - Bab 3.2 - Konfigurasi Eksperimen: tabel dan penjelasan seluruh parameter konstan pengujian (optimizer, *learning rate*, *batch size*, kriteria penghentian).

IV.2.2 Pernyataan Penggunaan AI Assistant

- **Tool yang dipakai:** Claude Sonnet 4.5
- **Untuk bagian apa:** *Drafting* dan iterasi kode untuk *training pipeline*, konfigurasi *callback*, ekstraksi *df_history*, serta konsultasi justifikasi pemilihan nilai hyperparameter (*learning rate* 3×10^{-4} , *batch size* 16, *patience* 15).
- **Tingkat ketergantungan:** Sedang, estimasi $\sim 40\%$ output berasal dari AI terutama pada *drafting* awal kode, sedangkan sisanya merupakan hasil pemahaman dan verifikasi mandiri terhadap output yang dihasilkan.
- **Pernyataan:** Saya memahami dan dapat mempertanggungjawabkan setiap baris kode dan teks yang saya klaim sebagai bagian saya. Seluruh keputusan teknis seperti pemilihan nilai hyperparameter, alasan penggunaan ReduceLROnPlateau sebagai pengganti *fixed schedule*, dan interpretasi hasil training merupakan hasil pemahaman saya sendiri yang dapat saya jelaskan secara lisan maupun tertulis.

4.3 Neyla Shakira NPM 2306250655

IV.3.1 Komponen yang Dikerjakan

Berikut adalah daftar konkret bagian proyek yang menjadi tanggung jawab penuh saya:

- **Kode/modul:** Menulis skrip matplotlib/seaborn untuk mem-plot hasil riwayat epoch pelatihan ke dalam format grafik garis terpisah (Perbandingan Training vs Validation Accuracy dan Loss).
- **Bagian laporan:** Menulis Bab II.1 (Tinjauan Pustaka), Bab III.3 (Metrik Evaluasi), Bab III.4 (Hasil Kuantitatif), dan Bab III.7 (Pembahasan).

- **Presentasi & Lainnya:** Menyusun halaman slide presentasi hasil kuantitatif dan memimpin penjelasan performa model.

IV.3.2 Pernyataan Penggunaan AI Assistant

- **Tool yang dipakai:** ChatGPT 4o dan GitHub Copilot.
- **Untuk bagian apa:** Membantu menyusun struktur kode visualisasi grafik, merapikan penjelasan metrik evaluasi, menyusun tabel *related work*, dan menyusun *draft* awal pembahasan hasil kuantitatif.
- **Tingkat ketergantungan:** Sedang, estimasi ~20-30% output awal dibantu AI; seluruh output AI direvisi dan dipahami ulang oleh penulis sebelum dimasukkan ke laporan.
- **Pernyataan:** Saya memahami dan dapat mempertanggungjawabkan setiap baris kode dan teks yang saya klaim sebagai bagian saya.

4.4 Putri Kiara Salsabila Arief NPM 2306250743

IV.4.1 Komponen yang Dikerjakan

Berikut adalah daftar konkret bagian proyek yang menjadi tanggung jawab penuh saya:

- **Kode/modul:** Menulis fungsi inferensi pengujian akhir untuk mengevaluasi model terlatih menggunakan Test Set, menghasilkan output skrip Classification Report, dan menulis skrip visualisasi Confusion Matrix multiclass.
- **Bagian laporan:** Mengurus administrasi awal (Lembar Pernyataan Orisinalitas, Abstrak dwibahasa), Bab I.3, Bab I.4, Bab III.6 (Hasil Kualitatif & Error Analysis), Bab IV, Bab V, serta melampirkan Appendix A dan B.
- **Presentasi & Lainnya:** Membuat halaman slide analisis kesalahan dan lembar kesimpulan penutup, serta bertindak sebagai integrator utama slide presentasi kelompok.

IV.4.2 Pernyataan Penggunaan AI Assistant

- **Tool yang dipakai:** Gemini dan Claude Sonnet.
- **Untuk bagian apa:** Membantu penyusunan dan *drafting* bagian laporan akhir (abstrak, tujuan, error analysis, kesimpulan); *autocomplete* saat menulis fungsi pengujian; dan debugging error skrip.
- **Tingkat ketergantungan:** Sedang, estimasi ~25% output laporan menggunakan asisten AI sebagai titik awal, namun seluruh konten diverifikasi, direvisi, dan dipahami secara mendalam.
- **Pernyataan:** Saya memahami dan dapat mempertanggungjawabkan setiap baris kode dan teks yang saya klaim sebagai bagian saya.

BAB 5

KESIMPULAN & PEKERJAAN LANJUTAN

5.1 Kesimpulan

1. **(Terhadap RM1)** *Pipeline* prapemrosesan yang diimplementasikan-konversi ke RGB 3-*channel*, *resize* bilinear ke 224×224 piksel, dan normalisasi piksel ke $[0, 1]$ -terbukti menghasilkan aliran tensor input yang stabil selama 20 *epoch* pelatihan. Sebanyak 981 dari 983 citra berhasil diproses (tingkat keberhasilan 99,80%); 2 file yang rusak terdeteksi dan dikecualikan secara otomatis tanpa menghentikan pipeline (Subbab III.1).
2. **(Terhadap RM2)** Implementasi CNN berbasis TensorFlow/Keras berhasil mengekstrak representasi fitur motif batik secara progresif, dibuktikan oleh peningkatan *training accuracy* dari nilai awal hingga 0,3994 pada *epoch* ke-20. Namun, kemampuan generalisasi model masih terbatas: *validation accuracy* terbaik hanya mencapai 0,2177 pada *epoch* ke-7 dari model final. Pada eksperimen komparasi, Arsitektur 1 (2 blok konvolusi, *dropout* 0,3) menghasilkan *val accuracy* tertinggi sebesar 0,1565 dan *val loss* terendah sebesar 2,8162, mengindikasikan bahwa penambahan kedalaman jaringan tidak efektif pada dataset berukuran sangat kecil (Subbab III.5).
3. **(Terhadap RM3)** Augmentasi data (pencerminan horizontal dan rotasi acak) belum berhasil sepenuhnya menekan *overfitting*. Model final menunjukkan *gap* akurasi akhir sebesar 0,1885 dan *gap loss* sebesar 1,0604 antara data *train* dan validasi. Hal ini mengindikasikan bahwa variasi augmentasi yang diterapkan belum cukup merepresentasikan keragaman nyata pada citra batik; augmentasi tambahan berupa *color jitter* dan *random crop* diperkirakan lebih efektif (Subbab III.7).
4. **(Analisis Kegagalan)** *Error analysis* mengidentifikasi tiga pasangan kelas yang paling sering bertukar: Parang–Lereng (kesamaan pola diagonal), Sidomukti–Sidoluhur (kesamaan geometri simetris keraton), dan Kawung–Ceplok (kesamaan distribusi motif berulang). Kegagalan ini konsisten dengan keterbatasan arsitektur CNN dangkal dalam membedakan pola fine-grained pada dataset yang sangat kecil (Subbab III.6).

5.2 Klaim Bonus Skor

- ☒ **B1. Evaluasi Komparatif & Iterasi** - bukti: komparasi tiga varian arsitektur CNN pada Subbab III.5 (Tabel 3.4) dengan analisis sensitivitas *hyperparameter*.
- ☐ **B2. Dataset Mandiri** - tidak diklaim; dataset yang digunakan adalah dataset publik dari Kaggle.
- ☒ **B3. Analisis Etika, Bias, & Keterbatasan** - bukti: identifikasi bias warna intra-kelas, bias *sampling* akibat ukuran dataset kecil, dan potensi bias representasi kultural motif batik pada Subbab III.6 dan III.7.

5.3 Pekerjaan Lanjutan (*Future Work*)

1. **Transfer Learning dengan Backbone Pretrained.** Mengganti arsitektur CNN buatan sendiri dengan *backbone* seperti EfficientNet-B0 atau MobileNetV3 yang di-*pretrain* pada ImageNet, kemudian melakukan *fine-tuning* pada dataset batik. Pendekatan ini diperkirakan dapat mendorong *val accuracy* ke kisaran 70–80% meski dataset berukuran kecil, berdasarkan preseden studi serupa pada domain tekstil.
2. **Augmentasi Data yang Lebih Agresif.** Menambahkan *color jitter* (variasi kecerahan, kontras, saturasi), *random crop* dengan aspek rasio acak, dan *random erasing* untuk mengatasi keragaman warna intra-kelas dan variasi kondisi pengambilan gambar yang menjadi penyebab utama kesalahan prediksi.
3. **Ekspansi Dataset melalui Akuisisi Mandiri.** Mengumpulkan citra batik tambahan secara langsung (pemotretan kain batik dari berbagai sudut dan kondisi pencahayaan) atau melalui *web scraping* dari repositori citra batik yang terlisensi, dengan target minimal 200 citra per kelas untuk 20 kelas.
4. **Interpretability dengan Grad-CAM.** Mengintegrasikan modul *Gradient-weighted Class Activation Mapping* (Grad-CAM) untuk memvisualisasikan area peta fitur yang paling berperan dalam prediksi setiap kelas, guna memvalidasi apakah model benar-benar belajar dari pola motif yang bermakna (bukan dari artefak latar belakang atau tekstur kain).
5. **Evaluasi pada Dataset Out-of-Domain.** Menguji model yang telah dilatih pada dataset Kaggle terhadap citra batik yang diambil secara mandiri (kondisi pencahayaan berbeda, sudut pengambilan bervariasi, resolusi kamera smartphone) untuk mengukur kemampuan generalisasi nyata model di luar distribusi data latih.

LAMPIRAN A

Berkas Metadata Proyek (JSON)

Berikut adalah isi berkas metadata.json yang dikumpulkan terpisah bersama laporan ini. Berkas ini digunakan oleh sistem *agentic AI* untuk men-*generate* pertanyaan ujian lisan yang dipersonalisasi berdasarkan kontribusi dan klaim penguasaan konsep masing-masing anggota.

```
{
  "kode_kelompok": "K09",
  "topik_pilihan": 1,
  "nama_topik": "Convolutional Neural Network (CNN)",
  "judul_proyek": "Klasifikasi Motif Batik Indonesia Menggunakan Convolutional Neural Network (CNN)",
  "mata_kuliah": "Kecerdasan Buatan (ENCE616029)",
  "semester": "Genap 2025/2026",
  "dosen_pengampu": "Muhammad Firdaus Syawaludin Lubis, PhD.",
  "abstrak_singkat": "Proyek ini bertujuan mengimplementasikan arsitektur Convolutional Neural Network (CNN) untuk klasifikasi 20 kelas motif batik Indonesia. Model dilatih pada dataset Kaggle (981 citra valid) dengan prapemrosesan berupa konversi RGB, resize 224x224, dan normalisasi. Eksperimen membuktikan arsitektur dengan 2 blok konvolusi dan dropout 0.3 berkinerja terbaik. Hasil 20 epoch pelatihan mencapai akurasi validasi 21.09%.",
  "dataset": {
    "nama": "Indonesian Batik Motifs Dataset",
    "sumber": "Kaggle",
    "url": "https://www.kaggle.com/datasets/dionisiusdh/indonesian-batik-motifs",
    "jumlah_kelas": 20,
    "total_citra_awal": 983,
    "total_citra_valid": 981,
    "split_rasio": "70/15/15"
  },
  "model": {
    "arsitektur": "CNN (2 Blok Konvolusi, Dropout 0.3)",
    "framework": "TensorFlow/Keras",
    "optimizer": "Adam",
    "loss_function": "sparse_categorical_crossentropy",
    "batch_size": 16,
    "epoch_final": 20,
    "random_seed": 42,
    "val_accuracy_final": 0.2109,
    "val_accuracy_best": 0.2177
  },
  "klaim_bonus": [
    "B1. Evaluasi Komparatif & Iterasi",
    "B3. Analisis Etika, Bias, & Keterbatasan"
  ],
  "tautan": {
    "github": "https://github.com/kiarasarie/ai-final-project-group9",
    "colab": "https://colab.research.google.com/drive/1TszaFNk9uXMN_gSxuKw6mi0ohvfV7345?usp"
  }
}
```

```

        =sharing",
        "dataset_mandiri": null,
        "video_demo": "https://youtu.be/SygNuw6bsRs"
    },
    "anggota": [
        {
            "nama": "Vanessa Kayla Zahra",
            "npm": "2306161901",
            "konsep_dikuasai_implementasi": [
                "Desain Arsitektur CNN (Keras Sequential API)",
                "Konfigurasi Conv2D, MaxPooling2D, Flatten, Dense",
                "Eksperimen Hyperparameter Tuning Arsitektur"
            ],
            "konsep_dikuasai_teoris": [
                "Landasan Teori Model CNN",
                "Operasi Konvolusi & Feature Maps",
                "Fungsi Aktivasi ReLU & Softmax"
            ],
            "bagian_laporan": [
                "Bab 2.2 (Landasan Teori)",
                "Bab 2.4 (Block Diagram)",
                "Bab 3.5 (Analisis Hyperparameter Tuning)"
            ]
        },
        {
            "nama": "Kharisma Aprilia",
            "npm": "2306223244",
            "konsep_dikuasai_implementasi": [
                "Konfigurasi Optimizer Adam & Loss Function",
                "Implementasi Callback EarlyStopping & ReduceLROnPlateau",
                "Eksekusi Full Training Pipeline"
            ],
            "konsep_dikuasai_teoris": [
                "Mekanisme Learning Rate Scheduling",
                "Indikasi Overfitting & Underfitting",
                "Strategi Regularisasi (Dropout & Early Stopping)"
            ],
            "bagian_laporan": [
                "Bab 2.5 (Flowchart Program)",
                "Bab 3.2 (Konfigurasi Eksperimen)"
            ]
        },
        {
            "nama": "Neyla Shakira",
            "npm": "2306250655",
            "konsep_dikuasai_implementasi": [
                "Visualisasi Riwayat Pelatihan (Matplotlib/Seaborn)",
                "Plot Kurva Akurasi & Loss",
                "Kompilasi Metrik Evaluasi Kuantitatif"
            ],
            "konsep_dikuasai_teoris": [
                "Tinjauan Pustaka (Related Work)",

```

```

        "Metrik Cross-Entropy Loss",
        "Interpretasi Konvergensi Training-Validation"
    ],
    "bagian_laporan": [
        "Bab 2.1 (Tinjauan Pustaka)",
        "Bab 3.3 (Metrik Evaluasi)",
        "Bab 3.4 (Hasil Kuantitatif)",
        "Bab 3.7 (Pembahasan)"
    ]
},
{
    "nama": "Putri Kiara Salsabila Arief",
    "npm": "2306250743",
    "konsep_dikuasai_implementasi": [
        "Fungsi Inferensi & Pengujian Test Set",
        "Ekstraksi Classification Report",
        "Visualisasi Confusion Matrix Multiclass"
    ],
    "konsep_dikuasai_teoris": [
        "Error Analysis & Edge Cases",
        "Kemiripan Visual Antar Kelas (Bias Intra-kelas)",
        "Evaluasi Kualitatif Pola Kegagalan Prediksi"
    ],
    "bagian_laporan": [
        "Abstrak",
        "Bab 1 (Pendahuluan)",
        "Bab 3.6 (Hasil Kualitatif & Error Analysis)",
        "Bab 5 (Kesimpulan)"
    ]
}
],
"ai_assistant_usage": {
    "digunakan": true,
    "tools": ["ChatGPT 4o", "Google Gemini 2.0 Flash", "Claude Sonnet 4.5", "GitHub Copilot"],
    "estimasi_persentase": 25,
    "catatan": "Digunakan untuk drafting laporan, perbaikan tata bahasa, referensi sintaks plotting, dan kerangka skrip pelatihan; seluruh konsep di-review mandiri."
}
}

```

LAMPIRAN B

Tautan Repositori & Dataset

GitHub repo:	https://github.com/kiarasarief/ai-final-project-group9
Google Colab:	https://colab.research.google.com/drive/1TszaFNk9uXMN_gSxuKw6miOohvfV7345?usp=sharing
Dataset (Kaggle):	https://www.kaggle.com/dionisiusdh/indonesian-batik-motifs
Dataset mandiri:	– (tidak ada; proyek menggunakan dataset publik)
Video demo:	https://youtu.be/SygNuw6bsRs

Status akses: Repositori GitHub bersifat publik; notebook Google Colab dapat diakses oleh siapa pun yang memiliki tautan (*anyone with the link can view*). Seluruh tautan di atas telah diverifikasi aktif dan dapat diakses per tanggal **25 Mei 2026**.

APPENDIX C

Research Participation Consent Form (*Informed Consent*)

C.1 Brief Explanation. *Research:* Development & validation of an *agentic AI* framework for supporting academic oral examinations. *Principal investigator:* Muhammad Firdaus Syawaludin Lubis, PhD., Department of Computer Engineering, Universitas Indonesia. *Co-investigator:* a final-year undergraduate student supervised by the principal investigator. *Contact:* firdaus.lubis@ui.ac.id. *Ethics review status:* **under review**. *Context:* data collection is conducted alongside the oral examination of the AI course's final assessment. The oral examination is held as part of the academic assessment regardless of the participant's research-participation choice.

C.2 Data Collected. Final report (PDF) and metadata.json file; audio and video recordings of the oral examination; automatic transcripts derived from those recordings; lecturer's *judgment* scores (*ground truth*) and AI system's *judgment* scores (test variable). **Not collected:** biometric data other than voice/face, or personal data beyond what is contained in the academic report.

C.3 Data Management. Participant names and student IDs (NPMs) will be stored **anonymously** - replaced with participant codes (P001, P002, ...) prior to analysis. The code-to-identity mapping table is stored separately, encrypted, and accessed only by the principal investigator. Publications (journal articles, conference papers, theses) will not contain individual identities. Data is stored with encryption on infrastructure managed by the research team; retention is 5 years after the research concludes, after which the data is permanently deleted. Access is limited to the principal and co-investigators; no third party may access without an amendment to this *consent*.

C.4 Participant Rights. (1) The right to decline participation without affecting the course grade. (2) The right to partial participation (e.g. report/metadata may be used, video recording may not). (3) The right to withdraw data at any time **until 30 June 2026** by emailing the principal investigator with the subject [Withdrawal] - [Name] - [NPM]; confirmation of deletion is provided within ≤ 7 working days. After 30 June 2026 the data will have entered the analysis phase and withdrawal becomes impractical. (4) The right to ask questions at any time to the principal investigator. (5) The right to receive a summary of the research findings once they are published (sent to the registered email).

C.5 Individual Consent. Each member completes their personal block on the following pages - one page per member. Tick **exactly one** of the three options (A / B / C), then sign with a wet signature or an *e-signature*.

Individual Consent – Member 1

Full name : Kharisma Aprilia
Student ID (NPM) : 2306223244
Email : kharismaapr31@gmail.com

I have read Sections C.1–C.4 and understood their contents. I voluntarily choose the following option:

- ☐ **Option A – Full Participation.** I consent to the use of my report, metadata, **and** the audio and video recordings of my oral examination for research purposes.
- ☒ **Option B – Limited Participation.** I consent to the use of my report, metadata, and audio recording, **but I do not consent to the video recording** of my oral examination being used for research. (The video recording will be deleted after the academic assessment is completed.)
- ☐ **Option C – Decline Participation.** I decline to participate in the research. (The academic oral examination proceeds as usual; there is no consequence to the grade.)

Participant's signature



(Kharisma Aprilia)

Date: 25 Mei 2026

Witness / researcher's signature

()

Date:

Individual Consent – Member 2

Full name : Neyla Shakira
Student ID (NPM) : 2306250655
Email : neylashakira110804@gmail.com

I have read Sections C.1–C.4 and understood their contents. I voluntarily choose the following option:

- ☐ **Option A – Full Participation.** I consent to the use of my report, metadata, **and** the audio and video recordings of my oral examination for research purposes.
- ☒ **Option B – Limited Participation.** I consent to the use of my report, metadata, and audio recording, **but I do not consent to the video recording** of my oral examination being used for research. (The video recording will be deleted after the academic assessment is completed.)
- ☐ **Option C – Decline Participation.** I decline to participate in the research. (The academic oral examination proceeds as usual; there is no consequence to the grade.)

Participant's signature



(Neyla Shakira)

Date: 25 Mei 2026

Witness / researcher's signature

()

Date:

Individual Consent – Member 3

Full name : Putri Kiara Salsabila Arief
Student ID (NPM) : 2306250743
Email : putrikaaara@gmail.com

I have read Sections C.1–C.4 and understood their contents. I voluntarily choose the following option:

- ☐ **Option A – Full Participation.** I consent to the use of my report, metadata, **and** the audio and video recordings of my oral examination for research purposes.
- ☒ **Option B – Limited Participation.** I consent to the use of my report, metadata, and audio recording, **but I do not consent to the video recording** of my oral examination being used for research. (The video recording will be deleted after the academic assessment is completed.)
- ☐ **Option C – Decline Participation.** I decline to participate in the research. (The academic oral examination proceeds as usual; there is no consequence to the grade.)

Participant's signature



(Putri Kiara Salsabila Arief)

Date: 25 Mei 2026

Witness / researcher's signature

()

Date:

Individual Consent – Member 4

Full name : Vanesa Kayla Zahra
Student ID (NPM) : 2306161901
Email : vanesakzahra@gmail.com

I have read Sections C.1–C.4 and understood their contents. I voluntarily choose the following option:

- ☐ **Option A – Full Participation.** I consent to the use of my report, metadata, **and** the audio and video recordings of my oral examination for research purposes.
- ☒ **Option B – Limited Participation.** I consent to the use of my report, metadata, and audio recording, **but I do not consent to the video recording** of my oral examination being used for research. (The video recording will be deleted after the academic assessment is completed.)
- ☐ **Option C – Decline Participation.** I decline to participate in the research. (The academic oral examination proceeds as usual; there is no consequence to the grade.)

Participant's signature



(Vanesa Kayla Zahra)

Date: 25 Mei 2026

Witness / researcher's signature

()

Date: